

GENERALIZED LINEAR MODELS

- Estendiamo i mod di regressione ordinari contemplando risposte non normali e modellizzando funzioni del valore atteso
- Sono caratterizzati da 3 componenti

1. Componente Casuale (Random Component)

Consiste di una v.a. Y , di cui si osservano N realizzazioni $\{y_1, \dots, y_N\}$, la cui distribuzione rientra nella fam esponenziale

$$f_Y(y_i; \theta_i) = a(\theta_i) b(y_i) \exp\{y_i Q(\theta_i)\}$$

\uparrow parametro della distrib
Può variare da y_1, \dots, y_N
 \Rightarrow non identicamente distrib

\uparrow PARAMETRO NATURALE

2. Componente Sistemática (Systematic Component)

Mette in relazione un vettore (η_1, \dots, η_N) con le variabili esplicative del modello. Detta x_{ij} il valore del j -esimo predittore dell'unità i -esima, allora

$$\eta_i = \underbrace{\sum_j \beta_j x_{ij}}_{\text{PREDITTORE LINEARE}} \quad i=1 \dots N$$

3. LINK FUNCTION

Connette componente sistemática e componente casuale. Detta $\mu_i = E[Y_i]$, $i=1 \dots N$, il modello prevede che

$$\eta_i = g(\mu_i) \Rightarrow g(\mu_i) = \sum_j \beta_j x_{ij}$$

\uparrow monotona e differenziabile

\swarrow classico lm

Oss: $g(\mu) = \mu$ IDENTITY LINK. Modello direttamente per la media
(Oss:) La link function che trasforma la media nel param naturale è detta LINK FUNCTION CANONICA

$$g(\mu_i) = Q(\theta_i) = \sum_j \beta_j x_{ij}$$

\Rightarrow Un GLM è un modello lineare per una trasformazione della media della var risp la cui distribuzione ricade nella fam esponenziale

Es 1: Binomial Logit Model for BINARY DATA

Binary responses of the form $Y = \begin{cases} 0 & (1-\pi) & P(Y=0) \\ 1 & \pi & P(Y=1) \end{cases}$

$$\Rightarrow E[Y] = P(Y=1) = \pi$$

↑
successo (ESEMPLI)

Caso particolare di $Y \sim \text{Bi}(n, \pi)$ con $n=1 \Rightarrow Y \sim \text{Be}(\pi)$

~ Componente casuale

$$f_Y(y; \pi) = \pi^y (1-\pi)^{1-y} = (1-\pi) \left[\frac{\pi}{1-\pi} \right]^y \mathbb{1}_{\{0,1\}}(y)$$

$$= (1-\pi) \exp \left\{ y \log \left(\frac{\pi}{1-\pi} \right) \right\} \mathbb{1}_{\{0,1\}}(y)$$

$\Rightarrow Y$ è fam. esponenziale in cui

$$\theta = \pi$$

$$a(\theta) = 1-\pi$$

$$b(y) = 1$$

$$Q(\theta) = \log \left(\frac{\pi}{1-\pi} \right) = \text{logit}(\pi)$$

LINK CANONICO

Es 2: Poisson Loglinear Model for COUNT DATA

La distribuzione più comunemente usata per modellizzare i conteggi è la Poisson

$$Y \sim P(\mu) \Rightarrow E[Y] = \mu$$

~ Componente Casuale

$$f_Y(y; \mu) = \frac{e^{-\mu} \mu^y}{y!} = \exp \{-\mu\} \cdot \frac{1}{y!} \exp \{y \log(\mu)\}$$

$\Rightarrow Y$ è fam. esponenziale in cui

$$\theta = \mu$$

$$a(\theta) = e^{-\mu}$$

$$b(y) = 1/y!$$

$$Q(\theta) = \log(\mu)$$

LINK CANONICO

Es 3: GLM for CONTINUOUS RESPONSES

Chiaramente i mod. generalizzati includono quelli tradizionali come caso particolare

$$f_Y = \mathcal{N} \quad Q(E[Y]) = E[Y] \quad (\text{link identità})$$

Ma poi ci sono tutte le altre distribuzioni continue (g, e, ...)

(Oss): Di solito i modelli lineari trasformano y in modo che sia distribuita N e con var costante, quindi otteniamo le stime via LS. Nei GLM la scelta di random component e link function sono separate. Non è necessario che il link stabilizzi la varianza o produca normalità.

DEVIANZA

Per un GLM e un insieme di osservazioni $\{y_1, \dots, y_N\}$ sia

$\ell(\underline{\mu}, \underline{y}) = \log$ Verosimiglianza espresso in termini di media

$\Rightarrow \ell(\hat{\underline{\mu}}, \underline{y})$ è la log Verosim massimizzata

$\ell(\underline{y}, \underline{y})$ è la log Verosim massima ottenibile considerando tutti i possibili modelli (è quella del modello generale che ha un parametro per ogni oss e produce il fit perfetto (interpolato) per cui $\hat{\underline{\mu}} = \underline{y}$)
Inutile in quanto non produce alcuna sintesi dei dati o' serve come baseline comparison

$$\text{DEVIANZA} = -2 [\ell(\hat{\underline{\mu}}, \underline{y}) - \ell(\underline{y}, \underline{y})] \leftarrow \text{statistica derivante dal rapporto di Verosimiglianze}$$

$\stackrel{\text{asint}}{\sim} \chi^2_{(N-p)}$ # of model param

$\hookrightarrow \lambda = -2 \log \left(\frac{\text{Lik}^1}{\text{Lik}^2} \right) = -2 (\log \text{Lik}^1 - \log \text{Lik}^2)$

Es: $Y_i \sim \text{Bi}(m_i, \pi_i)$, $i = 1 \dots N$

Immaginiamo di fare testare che $\pi_i = \alpha \forall i$, ovvero $\sqrt{\text{un mod}}$ con un solo parametro anziché N testare la bontà di

$\Rightarrow \text{DEVIANZA} \sim \chi^2_{(N-1)}$

L'auc delle devianza è una generalizzaz dell'ANOVA per variab risposta non Normali

GLM per DATI BINARI

Sia $Y \sim \text{Be}(\pi(x)) = \begin{cases} 0 & P(Y=0) = (1-\pi(x)) \\ 1 & P(Y=1) = \pi(x) \end{cases}$
per sottolineare dipendenza cov

Si ha pertanto che $E[Y] = \pi(x)$ $V[Y] = \pi(x)(1-\pi(x))$

Una prima idea per modellizzare Y attraverso $\pi(x)$ e' el'uti-
lizzo di un mod lineare della forma

$\pi(x) = \alpha + \beta x \rightarrow$ GLM con compon casuale Binomiale
e link identita'

PB1: cosi facendo nulla garantisce che $\pi \in [0,1]$ come dovrebbe

PB2: se volessimo stime LS dovremmo partire da v.a N (qui
 $Y \in \{0,1\}$) e con varianza costante (qui la varianza
e tanto minore quanto piu $x \rightarrow 0,1$)

\Rightarrow una relazione non lineare risponde meglio alle esigenze
In particolare, qualcosa che abbia minore impatto se $\pi \rightarrow 0,1$
che se $\pi \sim 0,5$. Storicamente la forma piu usata e' la logistica

$$\pi(x) = \frac{\exp\{\alpha + \beta x\}}{1 + \exp\{\alpha + \beta x\}}$$

se $\beta > 0 \Rightarrow \pi(x) \rightarrow 1$ se $x \rightarrow \infty$
se $\beta < 0 \Rightarrow \pi(x) \rightarrow 0$ se $x \rightarrow \infty$

$1 - \pi = 1 - \frac{\exp}{1 + \exp} = \frac{1 + \exp - \exp}{1 + \exp}$ $\Rightarrow \frac{\pi}{1 - \pi} = \frac{\exp}{1 + \exp} / \frac{1}{1 + \exp} = \exp$

ODD rapporto tra prob successo e insuccesso

$\frac{\pi(x)}{1 - \pi(x)} = \exp\{\alpha + \beta x\} \Rightarrow \log\left(\frac{\pi(x)}{1 - \pi(x)}\right) = \alpha + \beta x$

PARAM NATURALE

$\Rightarrow \text{logit}(\pi(x)) = \alpha + \beta x$

$g(\mu_i) = \eta_i = \sum_j \beta_j x_{ij}$

Interpretazione dei parametri β

Il segno di β determina se $\pi(x)$ aumenta o decresce al crescere di x , analogo al coeff angolare della retta di regressione

Dalle formule sopra abbiamo capito che in caso di un increm unitario di x , l'odd cresce di un fattore e^β

In altre parole

ODDS RATIO

$$\left. \begin{aligned} \frac{\pi(x=x+1)}{1 - \pi(x=x+1)} &= e^\alpha e^{\beta(x+1)} \\ \frac{\pi(x=x)}{1 - \pi(x=x)} &= e^\alpha e^{\beta x} \end{aligned} \right\} \Rightarrow \log\left(\frac{\frac{\pi(x=x+1)}{1 - \pi(x=x+1)}}{\frac{\pi(x=x)}{1 - \pi(x=x)}}\right) = \log\left(\frac{e^\alpha e^{\beta(x+1)}}{e^\alpha e^{\beta x}}\right) = \beta$$

ovvero e^β è un ODDS RATIO, e β misura l'incremento (5)
di rischio relativo (~~proprietà~~ rapporto tra prob di successo
e insuccesso) in corrispondenza di un incremento unitario
del regressore

↪ facile nel caso di regressore binario (tabella di contingenza)

Probit and Inverse CDF Link Functions

Analoghe alla Logistica sono altre funzioni link spesso usate
per connettere $\pi(x)$ al predittore lineare

$$\pi(x) = F(x) \Rightarrow F^{-1}(\pi(x)) = \sum_j \beta_j x_{ij}$$

$$\pi(x) = \Phi(x) \Rightarrow \Phi^{-1}(\pi(x)) = \sum_j \beta_j x_{ij} \quad \text{PROBIT}$$

(GLM per DATI di tipo CONTEGGIO)

La distribuz di Poisson ha media $\mu > 0$. Abbiamo visto in preced
che il log della media è il param naturale in un GLM con
resp Poisson e che il log è il suo link canonico. Pertanto

$$Y \sim P(\mu) \quad \log(\underbrace{\mu}_{E[Y]}) = \alpha + \beta x$$

Consideraz analoghe al caso logistico valgono per l'interpretaz dei
 β ecc ecc.

- Spesso capita però che i dati manifestino una variabilità maggiore
di quella ammessa da un mod di Poisson: OVERDISPERSION
Una delle principali cause è l'eterogeneità dei soggetti.

Di solito qto non è un pb nei soliti mod di regz perché c'è un
param apposto \times la varianza. Nel caso di Binomiale e Poisson
infine la varianza è una funz della media

⇒ Estensione: Negative Binomial

per k fissato
è un GLM

$$Y \sim f_Y(y; k, \mu) = \frac{\Gamma(y+k)}{\Gamma(k)\Gamma(y+1)} \left(\frac{k}{\mu+k}\right)^k \left(1 - \frac{k}{\mu+k}\right)^y$$

$$E[Y] = \mu \quad V[Y] = \mu + \frac{\mu^2}{k} \quad \text{se } \frac{1}{k} \rightarrow 0 \Rightarrow V[Y] \rightarrow \mu \text{ e } Y \rightarrow P$$

$1/k$ DISPERSION PARAM

MOMENTS & LIKELIHOOD for GLMs

(5)

Per sfruttare l'argomento della stima e dell'inferenza ci serve generalizzare la notazione fin qui introdotta per comprendere fam di variabili con più parametri

Sia quindi $\{y_1, \dots, y_N\}$ un campione da Y distribuite come

$$f_Y(y_i; \theta_i, \phi) = \exp \{ [y_i \theta_i - b(\theta_i)] / a(\phi) + c(y_i, \phi) \} \quad (1)$$

EXPONENTIAL DISPERSION FAMILY

Ci si riconduce alla forma precedente, per ϕ fissato, immaginando che

$$\eta(\theta) = \theta / a(\phi)$$

$$a(\theta) = \exp \{ -b(\theta) / a(\phi) \}$$

$$b(y) = \exp \{ c(y, \phi) \}$$

solitamente è della forma

$$a(\phi) = \phi / \omega_i$$

Es: $y_i \sim \text{Ber}(m_i)$ $i=1 \dots m \Rightarrow \omega_i = m_i$ ↑ pesi noti

Media e Varianza della componente casuale

Si possono ricavare espressioni generali per media e varianza a partire da (1). Sia $R_i = \log f_Y(y_i; \theta_i, \phi)$ e $L = \sum_i R_i$

$$\Rightarrow R_i = [y_i \theta_i - b(\theta_i)] / a(\phi) + c(y_i, \phi)$$

$$\Rightarrow \frac{\partial R_i}{\partial \theta_i} = [y_i - b'(\theta_i)] / a(\phi) \quad \frac{\partial^2 L}{\partial \theta_i^2} = -b''(\theta_i) / a(\phi)$$

Ora, sotto opportune hp di regolarità soddisfatte dalla fam exp, valgono i seguenti risultati generali relativi alle GLM

↳ Cox and Hinkley 1974

$$E \left[\frac{\partial L}{\partial \theta} \right] = 0 \quad - \quad E \left[\frac{\partial^2 L}{\partial \theta^2} \right] = E \left[\frac{\partial L}{\partial \theta} \right]^2$$

da cui si ricava che

$$i) \quad E \left[\frac{y_i - b'(\theta_i)}{a(\phi)} \right] = \frac{1}{a(\phi)} (E[y_i] - E[b'(\theta)]) = 0 \Rightarrow E[y_i] = b'(\theta_i)$$

$$ii) \quad \frac{b''(\theta_i)}{a(\phi)} = \left(E \left[\frac{y_i - b'(\theta_i)}{a(\phi)} \right] \right)^2 = \frac{1}{a(\phi)^2} (E[y - E[y]])^2 = \frac{\text{Var}[y_i]}{a(\phi)^2}$$

$$\Rightarrow \text{Var}[y_i] = b''(\theta_i) a(\phi)$$

$b(\cdot)$ è la funzione che determina i momenti di Y .

Esempio POISSON

(7)

$$Y \sim P(\mu) \Rightarrow f_{Y_i}(y_i; \mu) = \frac{e^{-\mu} \mu^{y_i}}{y_i!} = \exp\{y_i \log \mu - \mu - \log y_i!\}$$

$$\stackrel{\theta = \log(\mu)}{=} \exp\{y_i \theta - \exp(\theta) - \log y_i!\}$$

$$\Rightarrow \text{e exp disp family with } b(\theta_i) = \exp(\theta_i)$$

$$a(\phi) = 1$$

$$c(y_i, \phi) = -\log y_i!$$

$$\Rightarrow E[Y_i] = b'(\theta_i) = \exp(\theta_i) = \mu_i$$

$$V[Y_i] = b''(\theta_i)a(\phi) = \mu_i$$

Esempio BINOMIALE

$$m_i \overset{\text{proporz di successi su } m_i}{\downarrow} (Y_i) \sim \text{Bi}(m_i, \pi_i) \Rightarrow f_{Y_i}(y_i; m_i, \pi_i) = \binom{m_i}{m_i y_i} \pi_i^{m_i y_i} (1-\pi_i)^{m_i - m_i y_i}$$

$$\stackrel{\theta_i = \log(\pi_i)}{=} \exp\left\{ \frac{y_i \theta_i - \log(1 + \exp(\theta_i))}{1/m_i} + \log \binom{m_i}{m_i y_i} \right\}$$

$$\Rightarrow \text{e exp disp family with } b(\theta_i) = \log(1 + \exp(\theta_i))$$

$$a(\phi) = 1/m_i$$

$$c(y_i, \phi) = \log \binom{m_i}{m_i y_i}$$

$$\Rightarrow E[Y_i] = b'(\theta_i) = \frac{\exp(\theta_i)}{1 + \exp(\theta_i)} = \pi_i \quad \frac{\pi/(1-\pi)}{1 + \pi/(1-\pi)} = \frac{1-\pi}{1-\pi} \cdot \frac{\pi}{1-\pi+\pi} = \pi$$

$$V[Y_i] = b''(\theta_i)a(\phi) = \frac{\exp(\theta_i)}{[1 + \exp(\theta_i)]^2} \cdot \frac{1}{m_i} = \frac{\pi_i(1-\pi_i)}{m_i}$$

Nota: $m_i = g(\mu_i) = \sum_j \beta_j x_{ij}$. Inoltre abbiamo detto che g è link function tale per cui

$$\theta_i = \sum_j \beta_j x_{ij} \leftarrow g(\mu_i) = \theta_i$$

e' quella canonica

Dal momento che $\mu_i = b'(\theta_i) \Rightarrow \theta_i = (b')^{-1}(\mu_i)$

\Rightarrow la link canonica e' l'inversa di b

Likelihood Equations for GLMs

Per N osservazioni indipendenti, ~~ov~~

$$l(\beta) = \sum_i l_i = \sum_i \log f_Y(y_i; \theta_i, \phi) = \sum_i \frac{y_i \theta_i - b(\theta_i)}{a(\phi)} + \sum_i c(y_i, \phi)$$

La dipendenza da β è mascherata nel fatto che $\theta = \theta(\beta)$

Le score equations sono quindi

$$\frac{\partial l(\beta)}{\partial \beta_j} = \sum_i \frac{\partial l_i}{\partial \beta_j} = 0 \quad \forall j = 1, \dots, p$$

Applicando la chain rule

$$\frac{\partial l_i}{\partial \beta_j} = \underbrace{\left(\frac{\partial l_i}{\partial \theta_i} \right)}_A \cdot \underbrace{\left(\frac{\partial \theta_i}{\partial \mu_i} \right)}_B \cdot \underbrace{\left(\frac{\partial \mu_i}{\partial \eta_i} \right)}_C \cdot \underbrace{\left(\frac{\partial \eta_i}{\partial \beta_j} \right)}_D$$

A. $\frac{\partial l_i}{\partial \theta_i} = \frac{[y_i - b'(\theta_i)]}{a(\phi)} = \frac{y_i - \mu_i}{a(\phi)}$
 \uparrow
 $\mu_i = b'(\theta_i)$

D. $\frac{\partial \eta_i}{\partial \beta_j} = x_{ij}$ in quanto $\eta_i = \sum_j \beta_j x_{ij}$

B. $\frac{\partial \mu_i}{\partial \theta_i} = \frac{\text{Var}[Y_i]}{a(\phi)}$ in quanto $\begin{cases} \mu_i = b'(\theta_i) \Rightarrow \frac{\partial \mu_i}{\partial \theta_i} = b''(\theta_i) \\ \text{Var}[Y_i] = b''(\theta_i) a(\phi) \Rightarrow b''(\theta_i) = \frac{\text{Var}[Y_i]}{a(\phi)} \end{cases}$

C. dipende dalla link function del modello

$$\Rightarrow \frac{\partial l_i}{\partial \beta_j} = \frac{y_i - \mu_i}{a(\phi)} \cdot \frac{a(\phi)}{\text{Var}[Y_i]} \cdot \frac{\partial \mu_i}{\partial \eta_i} \cdot x_{ij} = \frac{(y_i - \mu_i) x_{ij}}{\text{Var}[Y_i]} \cdot \frac{\partial \mu_i}{\partial \eta_i}$$

$$\Rightarrow \frac{\partial l}{\partial \beta_j} = \sum_i \frac{(y_i - \mu_i) x_{ij}}{\text{Var}[Y_i]} \cdot \frac{\partial \mu_i}{\partial \eta_i} = 0$$

NB: dipendenza da β nascosta nel fatto che $\mu_i = g^{-1}\left(\sum_j \beta_j x_{ij}\right)$

Oss 1: Le eq della verosim dipendono dalle distrib di Y_i solo attraverso μ_i e $\text{Var}[Y_i]$

Oss 2: La Varianza dipende dalla media ~~ov~~ $\text{Var}[Y_i] = v(\mu_i)$

~> Poisson: $v(\mu_i) = \mu_i$

~> Bernoulli: $v(\mu_i) = \mu_i(1 - \mu_i)$

~> Normale: $v(\mu_i) = \sigma^2$ (i.e. constant)

Quando Y_i è fam exp, la relaz tra medie e varianza è costante

FITTING GLM

12

Algoritmo basato in sospeso come ottenere le stime dei parametri, dicendo che le scorse equations di solito nei GLM sono non lineari in $\beta \Rightarrow$ servono metodi iterativi

1. Newton-Raphson

Algoritmo iterativo per la soluz di sistemi non lineari

- Parte da una guess iniziale sulla soluz
- 1 Approssima la funz da massimizzare in un intorno del pto di cui in (0) tramite un polinomio di secondo grado e ne determina il max
- 2 Itera fino a convergenza

Più precisamente, sia

$$u' = \left(\frac{\partial L(\beta)}{\partial \beta_1}, \frac{\partial L(\beta)}{\partial \beta_2}, \dots \right)$$

$$H = \{ R_{ab} : R_{ab} = \frac{\partial^2 L(\beta)}{\partial \beta_a \partial \beta_b} \} \quad \text{HESSIANA}$$

Siano quindi $u^{(t)}$ e $H^{(t)}$ le loro valutazioni in $\beta^{(t)}$ ← guess solution for β all' iteraz t-esima

Allo step t, l'algoritmo approssima $L(\beta)$ nell'intorno di $\beta^{(t)}$ come

$$L(\beta) \approx L(\beta^{(t)}) + u^{(t)'} (\beta - \beta^{(t)}) + \frac{1}{2} (\beta - \beta^{(t)})^T H^{(t)} (\beta - \beta^{(t)})$$

Risolvendo

$$\frac{\partial L(\beta)}{\partial \beta} \approx u^{(t)} + H^{(t)} (\beta - \beta^{(t)}) = 0 \quad \leftarrow \text{cerco punto staz (max locale dell' approx polin)}$$

si ottiene la guess per il passo successivo

$$\beta^{(t+1)} = \beta^{(t)} - (H^{(t)})^{-1} u^{(t)}$$


assumendo H non singolare
(ma le routine risolvono il sist lin piuttosto che calcolare l'inverso)

Si prosegue finché la differenza di $L(\beta^{(t)})$ tra due istanti successivi è sufficientemente piccola.

Attualmente nulla assicura che la convergenza sia al massimo globale

La convergenza avviene in genere in modo abbastanza rapido, in quanto per t grandi vale che

$$|\beta_j^{(t+1)} - \hat{\beta}_j| \leq c |\beta_j^{(t)} - \hat{\beta}_j|^2 \quad c > 0$$



2. Fisher Scoring

Metodo iterativo del tutto analogo al Newton-Raphson se non nel fatto che usa il valore atteso dell' hessiana (EXPECTED INFORMATION) anziché l' hessiana stessa (OBSERVED INFORMATION) all' iterato dell' approssimazione polinomiale al second' ordine

Inferenza per i parametri di regressione

Test di ipotesi sui singoli regressori: $H_0: \beta_j = 0$ vs $H_1: \beta_j \neq 0$

WALD TEST $\frac{(\hat{\beta} - 0)^2}{\text{se}(\hat{\beta})^2} \sim \chi^2_{(1)}$

↑
anche visto come test $\hat{\beta} \sim N(0,1)$

↳ GOF ✓

Curve ROC e tab miscel

INFERENZA per GLM

Abbiamo introdotto in precedenza il modello saturato che per ogni osservazione introduce un diverso param. Qto modello fornisce il fit perfetto (interpolaz) ma non e' molto utile in quanto non fornisce alcuna sintesi parsimoniosa delle info del dataset, ne' si puo' usare x fare previsione. Tuttavia serve come termine di cfr.

Un mod saturato spiega tutte le variab tramite la componente sistematica.

Siano $\tilde{\theta}$ la stima di θ e $\tilde{\mu}_i = y_i \forall i$ le corrispondenti stime delle medie. Siano inoltre $\hat{\theta}$ e $\hat{\mu}_i$ le stime ML di un generico mod insaturo.

Allora la statistica

$$G = -2 \log \frac{\max \text{likelihood model}}{\max \text{likelihood sat model}} = -2 [L(\hat{\mu}, \underline{y}) - L(\underline{y}, \underline{y})]$$

descrive il LOF tra i 2 modelli. Essa rappresenta il rapporto di Verosim per testare la bonta' del mod in esame contro generiche alternative.

Recuperando l'espressione della likelihood,

$$\begin{aligned} -2 [L(\hat{\mu}, \underline{y}) - L(\underline{y}, \underline{y})] &= \\ &= 2 \sum_i [y_i \tilde{\theta}_i - b(\tilde{\theta}_i)] / a(\phi) - 2 \sum_i [y_i \hat{\theta}_i - b(\hat{\theta}_i)] / a(\phi) \end{aligned}$$

Essendo $a(\phi)$ di solito pari a ϕ / w_i ,

$$= 2 \sum_i w_i [y_i (\tilde{\theta}_i - \hat{\theta}_i) - b(\tilde{\theta}_i) + b(\hat{\theta}_i)] / \phi = \underbrace{D(\underline{y}; \hat{\mu}) / \phi}_{\text{SCALED DEVIANCE}}$$

Pu' grande e' la scaled deviance e maggiore e' il LOF che si ha considerando il modello ridotto

Per alcuni GLM la scaled deviance $\sim \chi^2$

Esempio BINOMIALE

$$X_i = m_i Y_i \sim \text{Bi}(m_i, \pi_i) \Rightarrow \hat{\theta}_i = \log(\hat{\pi}_i / (1 - \hat{\pi}_i))$$

$$\begin{aligned} b(\hat{\theta}_i) &= \log(1 + \exp\{\hat{\theta}_i\}) \\ &= -\log(1 - \hat{\pi}_i) \end{aligned}$$

Analogamente

$$\tilde{\theta}_i = \log(y_i / (1 - y_i))$$

$$b(\tilde{\theta}_i) = -\log(1 - y_i)$$

$$a(\phi) = 1/m_i \Rightarrow \phi = 1 \text{ e } w_i = m_i$$

Teorema

Per testare $H_0: \theta = \theta_0$ vs $H_1: \theta \neq \theta_0$, si supponga che $X_1 \dots X_m$ iid $\sim f_x(x; \theta)$, e che $\hat{\theta}$ sia lo stimatore ML di θ e che $f(\cdot)$ soddisfi le condizioni di regolarita' (...).

Allora, sotto H_0 e per $m \rightarrow \infty$

$$-2 \log \lambda(x) \xrightarrow{\mathcal{L}} \chi^2_{(1)}$$

Dimostrazione

$$\begin{aligned} -2 \log \lambda(x) &= -2 \log \left(\frac{L(\theta_0; x)}{L(\hat{\theta}; x)} \right) \\ &= -2 \ell(\theta_0) + 2 \ell(\hat{\theta}) \end{aligned}$$

Esponendo la log verosimiglianza in serie di Taylor attorno a $\hat{\theta}$, si ottiene

$$\begin{aligned} \ell(\theta_0) &= \ell(\hat{\theta}) + \cancel{\ell'(\hat{\theta})(\theta_0 - \hat{\theta})} + \ell''(\hat{\theta}) \frac{(\theta_0 - \hat{\theta})^2}{2} + \dots \\ &= \cancel{-2 \ell(\hat{\theta})} - \cancel{2 \ell''(\hat{\theta})} \frac{(\theta_0 - \hat{\theta})^2}{2} + \cancel{2 \ell(\hat{\theta})} \end{aligned}$$

$$\Rightarrow -2 \log \lambda(x) = -\ell''(\hat{\theta})(\theta_0 - \hat{\theta})^2$$

Ora, sotto le opportune hp di regolarita' (vedi CR) si puo' mostrare che

$$\hat{I}_m(\hat{\theta}) = E[(\log f(x; \hat{\theta}))^2] = -\ell''(\hat{\theta})$$

e che $\frac{1}{m} \hat{I}_m(\hat{\theta}) \xrightarrow{\mathbb{P}} I(\theta)$

Quindi, sotto H_0 ,

$$-2 \log \lambda(x) = -\ell''(\hat{\theta})(\theta_0 - \hat{\theta})^2 = \underbrace{\left(-\ell''(\hat{\theta}) \cdot \frac{1}{m I(\theta_0)} \right)}_{\substack{\mathbb{P} \\ \downarrow \\ I(\theta_0)}} \cdot \underbrace{\left(\frac{\sqrt{m^2}}{\left(\frac{1}{\sqrt{I(\theta_0)}} \right)^2} \cdot (\hat{\theta} - \theta_0)^2 \right)}_{\substack{\parallel \\ \left(\frac{\sqrt{m}(\hat{\theta} - \theta_0)}{1/\sqrt{I(\theta_0)}} \right)^2}}$$

Quindi per il teo di Slutsky

$$-2 \log \lambda(x) \xrightarrow{\mathcal{L}} \chi^2_1$$

$$\uparrow -2D = -2[\ell(\theta_0) - \ell(\hat{\theta})]$$

$\downarrow \mathcal{L}$ asintotica
efficienza
MLE
 χ^2_1

$$\begin{aligned}
 & \Rightarrow 2 \sum_i m_i \left\{ y_i \left(\log \frac{y_i}{1-y_i} - \log \frac{\hat{\pi}_i}{1-\hat{\pi}_i} \right) + \log(1-y_i) - \log(1-\hat{\pi}_i) \right\} \quad (10) \\
 & = 2 \sum_i m_i y_i \log \frac{m_i y_i}{m_i - m_i y_i} - 2 \sum_i m_i y_i \log \frac{m_i \hat{\pi}_i}{m_i - m_i \hat{\pi}_i} + 2 \sum_i m_i \log \frac{1-y_i}{1-\hat{\pi}_i} \\
 & = 2 \sum_i m_i y_i \left(\log \left(\frac{m_i y_i}{m_i - m_i y_i} \right) - \log \left(\frac{m_i \hat{\pi}_i}{m_i - m_i \hat{\pi}_i} \right) \right) + 2 \sum_i m_i \log \frac{1-y_i}{1-\hat{\pi}_i} \\
 & = 2 \sum_i m_i y_i \left(\log \frac{m_i y_i}{m_i \hat{\pi}_i} + \frac{m_i - m_i \hat{\pi}_i}{m_i - m_i y_i} \right) + 2 \sum_i m_i \log \frac{m_i - m_i y_i}{m_i - m_i \hat{\pi}_i} \\
 & = 2 \sum_i m_i y_i \log \frac{m_i y_i}{m_i \hat{\pi}_i} + 2 \sum_i m_i y_i \log \frac{m_i - m_i \hat{\pi}_i}{m_i - m_i y_i} + 2 \sum_i m_i \log \frac{m_i - m_i y_i}{m_i - m_i \hat{\pi}_i} \\
 & = 2 \sum_i \underbrace{(m_i y_i)}_{\# \text{ sucessos}} \log \frac{m_i y_i}{m_i \hat{\pi}_i} + 2 \sum_i \underbrace{(m_i - m_i y_i)}_{\# \text{ insucessos}} \log \frac{m_i - m_i y_i}{m_i - m_i \hat{\pi}_i}
 \end{aligned}$$

$$\Rightarrow \text{[Scribbled out content]}$$

LR Model Comparison using Deviance

Per i mod Poisson e Binom abbiamo visto che $\phi = 1$, pertanto

$$D(\underline{y}; \hat{\underline{\mu}}) = -2 [L(\hat{\underline{\mu}}, \underline{y}) - L(\underline{y}, \underline{y})]$$

Consideriamo ora 2 modelli M_0 con valori fissati $\hat{\underline{\mu}}_0$ e M_1 con valori fissati $\hat{\underline{\mu}}_1$, in cui M_0 sia nested in M_1 . Dal momento che la devianza massimizzata su un # ristretto di valori non può assumere valori più grandi, si avrà

$$L(\hat{\underline{\mu}}_0; \underline{y}) \leq L(\hat{\underline{\mu}}_1; \underline{y}) \Rightarrow D(\underline{y}; \hat{\underline{\mu}}_1) \leq D(\underline{y}; \hat{\underline{\mu}}_0)$$

simpler models have larger dev

Immaginando che valga M_1 , il LR test per le dif tra M_1 e M_0 usa la stat test

$$\begin{aligned} -2 [L(\hat{\underline{\mu}}_0; \underline{y}) - L(\hat{\underline{\mu}}_1; \underline{y})] &= -2 [L(\hat{\underline{\mu}}_0; \underline{y}) - L(\underline{y}; \underline{y})] - \{-2 [L(\hat{\underline{\mu}}_1; \underline{y}) - L(\underline{y}; \underline{y})]\} \\ &= D(\underline{y}; \hat{\underline{\mu}}_0) - D(\underline{y}; \hat{\underline{\mu}}_1) \end{aligned}$$

\Rightarrow la LR statistics che confronta i due modelli non è altro che la diff tra le devianze.

La statistica test assume valori grandi quando M_0 produce un fit molto più insoddisfatto (significativamente più povero) di M_1

$$\begin{aligned} &= 2 \sum_i w_i [y_i (\hat{\theta}_{1i} - \hat{\theta}_{0i}) - b(\hat{\theta}_{1i}) + b(\hat{\theta}_{0i})] \\ &\approx \chi^2_{(df)} \end{aligned}$$

opportune hp di regressione generalm soddisfatte da fam exp

$(df) = (p_{M_1} - p_{M_0})$ # param M_1 - # param M_0

Residui

Come sempre se un mod produce un fitting insoddisfatto, l'analisi dei residui permette di capire dove in particolare il modello è povero.

Nel caso dei GLM, si possono considerare vari tipi di residui

1. Deviance Residuals: $\sqrt{d_i} \times \text{sgn}(y_i - \hat{\mu}_i)$ $d_i = 2w_i [y_i (\hat{\theta}_i - \hat{\theta}_i) - b(\hat{\theta}_i) + b(\hat{\theta}_i)]$
2. Pearson Residuals: $e_i = \frac{y_i - \hat{\mu}_i}{\text{Var}[Y_i]^{1/2}}$

C'è anche un analogo degli studentized residuals e dei leverage